Rendu n°1: CASSANDRA

Groupe: Adèle MONTOYA, Eleonor KIOULOU, Paul RUNAVOT

Classe: ESILV S8, DIA 4

Presentation of the dataset

We worked on the Companies (2) dataset.

This database contains:

- basic information about companies like the name, the location, the url of the homepage, the category of companie
- specific data like the amount about investments, acquisitions, type, currency...

Insertion of the dataset

We encountered some problems about the insertion of our dataset in cassandra. Firstly, the limit of the data insertion limit. Our dataset has a lot of data which exceeds the limit of data supported by the cassandra "by default", we had to find a way to unlock this limitation.

```
) docker cp cqlshrc 84fa0c09a52f:/root/.cassandra/
```

After this, another problem arose. after severals research, we found that the "delimiter" was the problem and we change it by "|"but even with that delimiter, some rows do not insert into the table. So we didn't have the choice to continue like this.

Simple queries (6)

1) Sélectionner les entreprises ayant pour catégorie "Software" :

2) Compter les entreprises ayant pour catégorie "Software" :

```
cqlsh:comp> SELECT COUNT(*) FROM companies WHERE category_code='software' ALLOW FILTERING;
count
-----
1593
(1 rows)
```

3) Sélectionner et compter les entreprises ayant plus de 5000 employés :

```
| Control | Cont
```

```
cqlsh:comp> SELECT COUNT(*) FROM companies WHERE number_of_employees > 5000 ALLOW FILTERING;
count
-----
41
(1 rows)
```

4) Compter le nombre d'entreprises dans chaque pays en utilisant le code pays "country_code"

```
founded_year
cqlsh:comp> SELECT COUNT(*) FROM companies WHERE founded_year<1950 ALLOW FILTERING;
count
```

```
(1 rows)
6)
```

7) Sélectionner les entreprise avec plus de cinq acquisitions:

SELECT name, acquisitions FROM companies WHERE acquisitions > 5;

- 8) Sélectionnez les entreprises dont les coordonnées GPS sont définies
- 9) Sélectionnez toutes les entreprises qui ont au moins un partenaire

Complex queries (2)

5)

1) Groupement des entreprises en fonction de leur catégorie et calcul du nombre d'entreprises pour chaque catégorie

SELECT category_code, count(id) FROM companies GROUP BY category_code

2) Sélectionner les entreprises avec plus de cinq acquisitions

Hard queries (1)

1) Tri des entreprises en fonction de la distance entre leur siège social (lat et lon dans coordinates de la colonne "offices") et Paris.